생명과학자료분석

수업 로그 선형분석 생략하고 로지스틱만 진행함

4 장 로짓 및 로그-선형 분석

전북대학교 통계학과

반응변수가 범주형일 때 자주 사용되는 분석방법

4.1 로짓분석 (logit analysis) 로지스틱 회귀분석 (logistic regression)

- 반응값이 연속적이지 않고 성공/실패, 생존/사망 등의 두 개의 범주이거나 또는 그 이상의 범주로 나뉘어져 있는 경우
- 성공확률을 추정하고, 그 값에 유의한 영향을 미치는 설명변수가 무엇인가를 알아보는 문제에 관심

4.2 로그-선형분석(log-linear model)

- 반응변수와 설명변수의 구분이 뚜렷하지 않고 각 변수가 범주형인 경우
- 각 변수들 간의 연관성을 알아보기 위한 방법 – 로그-선형 모형
- 모든 변수들을 반응변수로 보고 각 변수들 간의 연관성과 교호작용에 초점을 맞추어 분석

로짓분석

로지스틱 회귀분석(logistic regression) 또는 로짓분석(logit analysis)

- 회귀모형 Univariate logistic regression
  - 반응변수 - 범주형 예)성공/실패, 생존/사망 등
    - 이항 반응변수
    - 다항 반응변수 순서형/명목형
  - 설명변수(공변량)
- 질병과 연관 있는 위험요인 식별하거나 임상연구 자료에서 중요한 요인 식별하는 탐색적 분석에 적용

로짓분석

허혈성 심근병증 발생과 관련된 독립적 요인 예측인자

단변량 회귀분석 결과 허혈성 심근병증 독립적 예측인자는 연령 65세 이상, ST 분절 상승 심근경색증, Killip class Ⅱ 이상, WBC ≥ 10,000/mm³, CK-MB, troponin I, LVEF < 50%, LVEDD > 55 mm, E/e' ratio ≥ 15, E/A ratio ≥ 1.0, 심장사건, 스텐트 혈전증, 급성 신손상, 심폐 소생술, 병원재원 기간, 베타차단제, 안지오텐신 수용체 차단제였다. 다변량 로지스틱 회귀분석 결과 허혈성 심근병증의 독립적인 예측인자는 LVEF < 50% (OR 8.722, CI 2.986-25.478, p< 0.001), LVEDD > 55 mm (OR 4.511, CI 1.561-13.038, p= 0.005), E/e' ratio ≥ 15 (OR 3.270, CI 1.168-9.155, p= 0.024)로 파악되었다(Table 7).

Table 7.

Predictors of ischemic cardiomyopathy according to multivariate logistic regression analysis

	Univariate			Multivariate		
	OR	95% CI	p-value	OR	95% CI	p-value
Age ≥ 65 (years)	2.199	1.285–3.764	0.004	2.016	0.737–5.511	0.172
STEMI	2.181	1.275–3.732	0.004	0.984	0341–2.839	0.976
Killip class ≥ Ⅱ	2.090	1.203–3.633	0.009	0.741	0.267–2.057	0.565
SBP < 100 (mmHg)	1.478	0.591–3.695	0.403			
WBC (≥ 10,000/mm³)	2.505	1.428–4.394	0.001	2.917	0.963–8.837	0.058
Glucose (≥ 200 mg/dL)	1.741	0.991–3.057	0.054			
CK-MB (per 1 ng/mL)	1.006	1.003–1.008	< 0.001	1.002	0.997–1.007	0.380
Troponin I (per 1 ng/mL)	1.012	1.009–1.016	< 0.001	1.008	1.000–1.016	0.052
LVEF < 50%	14.876	7.542–29.344	< 0.001	8.722	2.986–25.478	< 0.001
LVEDD > 55 mm	7.817	4.210–14.516	< 0.001	4.511	1.561–13.038	0.005

Example 4.1

102명의 백혈병 환자를 랜덤하게 두 개의 그룹으로 나누어서 한 그룹에는 처리 A를 하고, 다른 그룹에는 처리 B를 하여 재발여부를 조사하였다. 이때 재발 여부에 영향을 미칠 수 있는 또 하나의 요인은 호전기간(remission time)이다. 데이터는 [표4.2]와 같다. X는 호전기간(단위:월)이며, Y는 재발여부로 재발 안한 경우 $Y = 0$, 재발한 경우 $Y = 1$로 코딩되었다. 처리와 호전기간이 재발여부에 어떠한 영향을 미치는지 알아보자.

평균 비교

- 설명변수

  $X1$: 처리 - A, B: 질적가변수 1개

  $X2$: 호전기간 - 개월수 : 양적

- 반응변수

  Y:재발여부- 0,1: 질적(이항변수)

변수
- 처리
- 재발여부
- 호전기간

변수 n개면 가변수는 n-1개
하나는 000으로 처리하면 돼서

Example 4.1

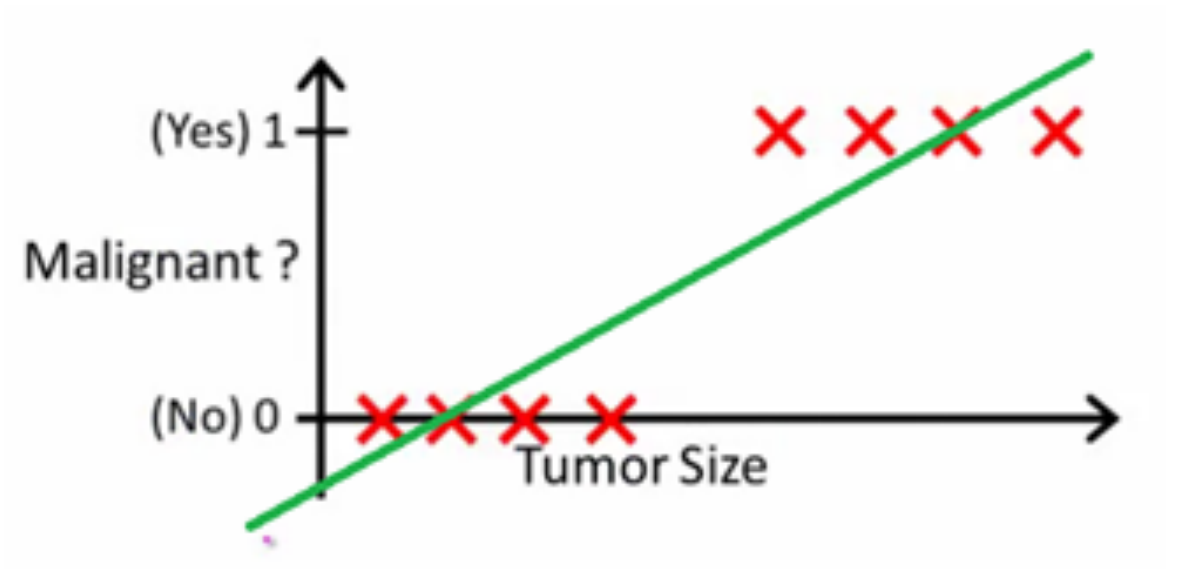
[표 4.2] 백혈병환자의 재발 자료

처리	번호	X	Y	번호	X	Y	번호	X	Y
	1	3	0	18	9	0	35	12	0
	2	3	1	19	6	1	36	12	0
	3	3	1	20	6	0	37	12	0
	4	6	1	21	6	0	38	9	1
	5	15	0	22	6	0	39	6	1
	6	6	1	23	3	1	40	12	0
	7	6	1	24	18	0	41	6	0
	8	6	1	25	9	0	42	15	1
A	9	15	0	26	12	1	43	9	0
	10	15	0	27	6	0	44	3	1
	11	12	0	28	9	1	45	9	0
	12	18	0	29	9	1	46	9	0
	13	6	1	30	3	0	47	9	0
	14	15	0	31	9	1	48	9	0
	15	6	1	32	12	0	49	9	1
	16	15	0	33	12	0	50	12	1
	17	12	1	34	3	0	51	3	1
	52	9	1	69	15	0	86	9	1
	53	3	0	70	15	1	87	15	0
	54	12	1	71	9	0	88	15	0
	55	3	1	72	9	0	89	12	0
	56	3	1	73	12	1	90	9	0
	57	15	1	74	3	1	91	12	0
	58	9	1	75	6	1	92	15	0
	59	12	1	76	6	1	93	18	1
B	60	3	1	77	12	0	94	12	0
	61	9	1	78	12	0	95	15	1
	62	15	1	79	12	1	96	15	0
	63	9	1	80	3	1	97	15	0
	64	6	1	81	12	1	98	18	0
	65	9	1	82	3	1	99	18	1

이항 반응변수의 경우

개체번호	반응변수	설명변수
1	y_1	$x_{11}, x_{21}, \ldots, x_{k1}$
2	y_2	$x_{12}, x_{22}, \ldots, x_{k2}$
$\ldots$	$\ldots$	$\ldots$
N	y_N	$x_{1N}, x_{2N}, \ldots, x_{kN}$

이항 반응변수의 경우



- Y의 기댓값 = 반응변수 Y 의 성공확률 : $E(Y) = P(Y = 1) = p$
- 설명변수가 조건으로 주어진 경우

$$E(Y|X = x) = P(Y = 1|X = x) = p_x$$

$$P(Y = y|X = x) = p_x^y(1 - p_x)^{1-y}, \ y = 0, 1$$

이항 반응변수의 경우

성공확률 p_x에 대한 모형

- 선형 확률 모형(linear probability model) : $p_x = \alpha + \beta x$

  성공확률 p_x 가 0과 1을 벗어날 수 있음

  고로 선형식 사용불가

- 로짓 모형 (logit model) : $p_x = \dfrac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}$

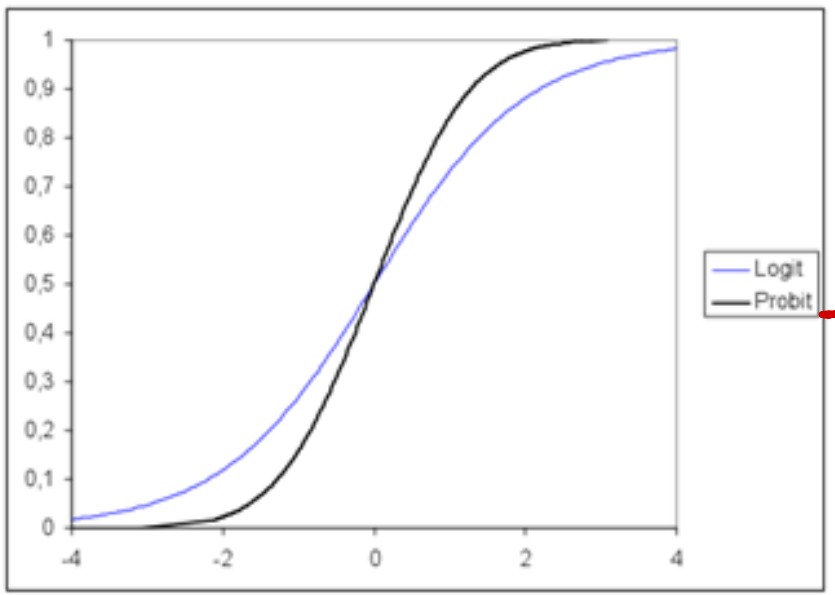
  $\beta > 0$:증가하는 곡선

  $\beta = 0$: 성공확률이 설명변수와 무관

  $\beta < 0$: 감소하는 곡선

  곡선의 변화율은 $|\beta|$가 커짐에 따라 커짐

표준정규분포 cdf의 역함수



로짓 모형 (logit model)

- 성공할 오즈(odds)

$$\frac{p_x}{1-p_x} = e^{\alpha+\beta x}$$

$e^{\alpha} * e^{\beta x}$ 이므로

설명변수 X가 한 단위 증가할 때마다 오즈는 e^{β}배 증가

- 로그 오즈

Alpha, beta를 추정해야함(회귀모형처럼)
이 때, mle가 사용된다.

$$\log \frac{p_x}{1-p_x} = \alpha + \beta x \quad (\leftarrow \text{로짓모형(logit model)}$$

- k개의 설명변수 $X-1,\ldots,X_k$가 있는 로짓 모형

$$p_x = \frac{e^{\alpha+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k}}{1+e^{\alpha+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k}}$$

$$\log \frac{p_x}{1-p_x} = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k$$

로짓 모형 (logit model)의 추정

최대 가능도 추정량

- $X = x$가 주어져 있을 때 Y의 조건부 확률밀도함수

$$P(Y = y|X = x) = p_x^y(1 - p_x)^{1-y}, \ y = 0, 1$$

- 로짓 모형

$$p_x = \frac{e^{\alpha+\beta x}}{1 + e^{\alpha+\beta x}} \ \Leftrightarrow \ \log \frac{p_x}{1 - p_x} = \alpha + \beta x$$

- 가능도함수

$$\begin{aligned} L(\alpha, \beta) &= \prod_{i=1}^{n} P(Y_i = y_i|X_i = x_i) = \prod_{i=1}^{n} p_{x_i}^{y_i}(1 - p_{x_i})^{1-y_i} \\ &= \prod_{i=1}^{n} \left(\frac{e^{\alpha+\beta x_i}}{1 + e^{\alpha+\beta x_i}} \right)^{y_i} \left(1 - \frac{e^{\alpha+\beta x_i}}{1 + e^{\alpha+\beta x_i}} \right)^{1-y_i} \end{aligned}$$

- 가능도함수 $L(\alpha, \beta)$를 최대로 하는 $\widehat{\alpha}, \widehat{\beta}$

로짓 모형 (logit model)의 검정

설명변수와 연관성

회귀계수의 유의성 검정

- 가설

$$H_0 : \beta_i = 0 \ vs \ H_1 : \beta_i \neq 0$$

- Wald 검정통계량

$$\left(\frac{\widehat{\beta}_i}{SE_{\widehat{\beta}_i}} \right)^2 \dot{\sim} \chi^2(1)$$

MLE는 근사적으로 정규분포를 따른다.

Example 4.1 SAS

```
data liver;
infile '예제4_1.txt' expandtabs;
input trt$ remission y ;
run;

proc print; run;

proc means mean std;
var remission;
run;

proc freq data=liver;
table trt*y;
run;

proc sgplot data=liver;
scatter x=remission y=y /jitter;
run;
```

Example 4.1 SAS

```
proc logistic descending;
   class trt(ref="B");
   model y=trt remission/scale=none aggregate;
   output out=estimated predicted=estprob l=lower95 u=upper95;
run;
```

```
proc print data=estimated; run;
```

```
proc logistic plots(only)=(effect oddsratio (type=horizontalstat) );
   class trt(ref="B");
   model y(event='1')=trt remission/scale=none aggregate lackfit clodds=both;
   unit remission=12;
run;
```