생명과학자료분석

4 장 로짓 및 로그-선형 분석

전북대학교 통계학과

반응변수가 범주형일 때 자주 사용되는 분석방법

4.1 로짓분석 (logit analysis) 로지스틱 회귀분석 (logistic regression)

- 반응값이 연속적이지 않고 성공/실패, 생존/사망 등의 두 개의 범주이거나 또는 그 이상의 범주로 나뉘어져 있는 경우
- 성공확률을 추정하고, 그 값에 유의한 영향을 미치는 설명변수가 무엇인가를 알아보는 문제에 관심

4.2 로그-선형분석(log-linear model)

- 반응변수와 설명변수의 구분이 뚜렷하지 않고 각 변수가 범주형인 경우
- 각 변수들 간의 연관성을 알아보기 위한 방법 – 로그-선형 모형
- 모든 변수들을 반응변수로 보고 각 변수들 간의 연관성과 교호작용에 초점을 맞추어 분석

로짓분석

로지스틱 회귀분석(logistic regression) 또는 로짓분석(logit analysis)

- 회귀모형
  - 반응변수 - 범주형 예)성공/실패, 생존/사망 등
    - 이항 반응변수
    - 다항 반응변수 순서형/명목형
  - 설명변수(공변량)
- 질병과 연관 있는 위험요인 식별하거나 임상연구 자료에서 중요한 요인 식별하는 탐색적 분석에 적용

로짓분석

허혈성 심근병증 발생과 관련된 독립적 요인 예측인자

단변량 회귀분석 결과 허혈성 심근병증 독립적 예측인자는 연령 65세 이상, ST 분절 상승 심근경색증, Killip class Ⅱ 이상, WBC ≥ 10,000/mm³, CK-MB, troponin I, LVEF < 50%, LVEDD > 55 mm, E/e' ratio ≥ 15, E/A ratio ≥ 1.0, 심장사건, 스텐트 혈전증, 급성 신손상, 심폐 소생술, 병원재원 기간, 베타차단제, 안지오텐신 수용체 차단제였다. 다변량 로지스틱 회귀분석 결과 허혈성 심근병증의 독립적인 예측인자는 LVEF < 50% (OR 8.722, CI 2.986-25.478, p< 0.001), LVEDD > 55 mm (OR 4.511, CI 1.561-13.038, p= 0.005), E/e' ratio ≥ 15 (OR 3.270, CI 1.168-9.155, p= 0.024)로 파악되었다(Table 7).

Table 7.

Predictors of ischemic cardiomyopathy according to multivariate logistic regression analysis

	Univariate			Multivariate		
	OR	95% CI	p-value	OR	95% CI	p-value
Age ≥ 65 (years)	2.199	1.285–3.764	0.004	2.016	0.737–5.511	0.172
STEMI	2.181	1.275–3.732	0.004	0.984	0341–2.839	0.976
Killip class ≥ Ⅱ	2.090	1.203–3.633	0.009	0.741	0.267–2.057	0.565
SBP < 100 (mmHg)	1.478	0.591–3.695	0.403			
WBC (≥ 10,000/mm³)	2.505	1.428–4.394	0.001	2.917	0.963–8.837	0.058
Glucose (≥ 200 mg/dL)	1.741	0.991–3.057	0.054			
CK-MB (per 1 ng/mL)	1.006	1.003–1.008	< 0.001	1.002	0.997–1.007	0.380
Troponin I (per 1 ng/mL)	1.012	1.009–1.016	< 0.001	1.008	1.000–1.016	0.052
LVEF < 50%	14.876	7.542–29.344	< 0.001	8.722	2.986–25.478	< 0.001
LVEDD > 55 mm	7.817	4.210–14.516	< 0.001	4.511	1.561–13.038	0.005

이항 반응변수의 경우

Example 4.1

102명의 백혈병 환자를 랜덤하게 두 개의 그룹으로 나누어서 한 그룹에는 처리 A를 하고, 다른 그룹에는 처리 B를 하여 재발여부를 조사하였다. 이때 재발 여부에 영향을 미칠 수 있는 또 하나의 요인은 호전기간(remission time)이다. 데이터는 [표4.2]와 같다. X는 호전기간(단위:월)이며, Y는 재발여부로 재발 안한 경우 $Y = 0$, 재발한 경우 $Y = 1$로 코딩되었다. 처리와 호전기간이 재발여부에 어떠한 영향을 미치는지 알아보자.

- 설명변수

  $X1$: 처리 - A, B: 질적가변수 1개

  $X2$: 호전기간 - 개월수 : 양적

- 반응변수

  Y:재발여부- 0,1: 질적(이항변수)

Example 4.1

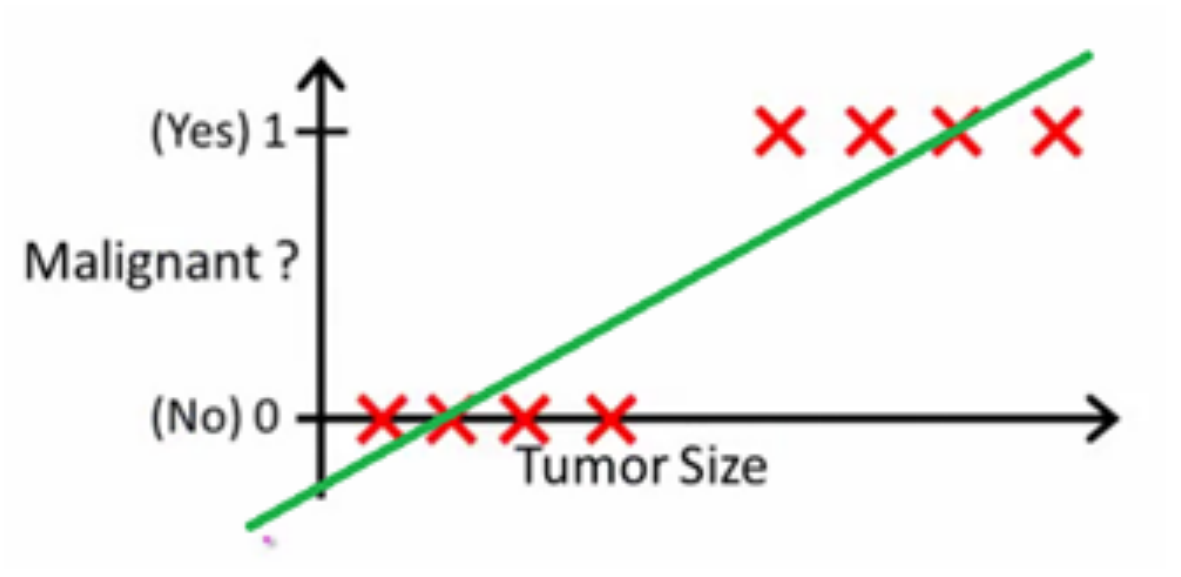
[표 4.2] 백혈병환자의 재발 자료

처리	번호	X	Y	번호	X	Y	번호	X	Y
	1	3	0	18	9	0	35	12	0
	2	3	1	19	6	1	36	12	0
	3	3	1	20	6	0	37	12	0
	4	6	1	21	6	0	38	9	1
	5	15	0	22	6	0	39	6	1
	6	6	1	23	3	1	40	12	0
	7	6	1	24	18	0	41	6	0
	8	6	1	25	9	0	42	15	1
A	9	15	0	26	12	1	43	9	0
	10	15	0	27	6	0	44	3	1
	11	12	0	28	9	1	45	9	0
	12	18	0	29	9	1	46	9	0
	13	6	1	30	3	0	47	9	0
	14	15	0	31	9	1	48	9	0
	15	6	1	32	12	0	49	9	1
	16	15	0	33	12	0	50	12	1
	17	12	1	34	3	0	51	3	1
	52	9	1	69	15	0	86	9	1
	53	3	0	70	15	1	87	15	0
	54	12	1	71	9	0	88	15	0
	55	3	1	72	9	0	89	12	0
	56	3	1	73	12	1	90	9	0
	57	15	1	74	3	1	91	12	0
	58	9	1	75	6	1	92	15	0
	59	12	1	76	6	1	93	18	1
B	60	3	1	77	12	0	94	12	0
	61	9	1	78	12	0	95	15	1
	62	15	1	79	12	1	96	15	0
	63	9	1	80	3	1	97	15	0
	64	6	1	81	12	1	98	18	0
	65	9	1	82	3	1	99	18	1

이항 반응변수의 경우

개체번호	반응변수	설명변수
1	y_1	$x_{11}, x_{21}, \ldots, x_{k1}$
2	y_2	$x_{12}, x_{22}, \ldots, x_{k2}$
$\ldots$	$\ldots$	$\ldots$
N	y_N	$x_{1N}, x_{2N}, \ldots, x_{kN}$

이항 반응변수의 경우



- Y의 기댓값 = 반응변수 Y 의 성공확률 : $E(Y) = P(Y = 1) = p$
- 설명변수가 조건으로 주어진 경우

$$E(Y|X = x) = P(Y = 1|X = x) = p_x$$

$$P(Y = y|X = x) = p_x^y(1 - p_x)^{1-y}, \ y = 0, 1$$

이항 반응변수의 경우

성공확률 p_x에 대한 모형

- 선형 확률 모형(linear probability model) : $p_x = \alpha + \beta x$

  성공확률 p_x 가 0과 1을 벗어날 수 있음

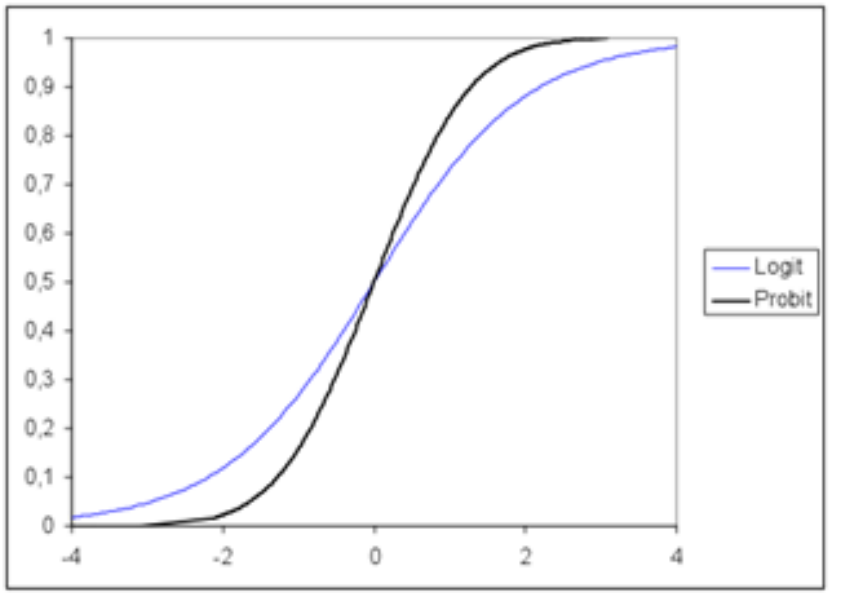
- 로짓 모형 (logit model) : $p_x = \dfrac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}$

  $\beta > 0$:증가하는 곡선

  $\beta = 0$: 성공확률이 설명변수와 무관

  $\beta < 0$: 감소하는 곡선

  곡선의 변화율은 $|\beta|$가 커짐에 따라 커짐



로짓 모형 (logit model)

- 성공할 오즈(odds)

$$\frac{p_x}{1-p_x} = e^{\alpha+\beta x}$$

  설명변수 X가 한 단위 증가할 때마다 오즈는 e^{β}배 증가

- 로그 오즈

$$\log \frac{p_x}{1-p_x} = \alpha + \beta x \quad (\leftarrow \text{로짓모형(logit model)}$$

- k개의 설명변수 $X_1, \ldots, X_k$가 있는 로짓 모형

$$p_x = \frac{e^{\alpha+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k}}{1+e^{\alpha+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k}}$$

$$\log \frac{p_x}{1-p_x} = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k$$

로짓 모형 (logit model)의 추정

최대 가능도 추정량

- $X = x$가 주어져 있을 때 Y의 조건부 확률밀도함수

$$P(Y = y|X = x) = p_x^y(1 - p_x)^{1-y}, \ y = 0, 1$$

- 로짓 모형

$$p_x = \frac{e^{\alpha+\beta x}}{1 + e^{\alpha+\beta x}} \ \Leftrightarrow \ \log \frac{p_x}{1 - p_x} = \alpha + \beta x$$

- 가능도함수

$$L(\alpha, \beta) = \prod_{i=1}^{n} P(Y_i = y_i|X_i = x_i) = \prod_{i=1}^{n} p_{x_i}^{y_i}(1 - p_{x_i})^{1-y_i}$$
$$= \prod_{i=1}^{n} \left(\frac{e^{\alpha+\beta x_i}}{1 + e^{\alpha+\beta x_i}} \right)^{y_i} \left(1 - \frac{e^{\alpha+\beta x_i}}{1 + e^{\alpha+\beta x_i}} \right)^{1-y_i}$$

로짓 모형 (logit model)의 검정

설명변수와 연관성

회귀계수의 유의성 검정

- 가설

$$H_0 : \beta_i = 0 \ vs \ H_1 : \beta_i \neq 0$$

- Wald 검정통계량

$$\left(\frac{\widehat{\beta}_i}{SE_{\widehat{\beta}_i}} \right)^2 \dot{\sim} \chi^2(1)$$

Example 4.1 SAS

```
data liver;
infile '예제4_1.txt' expandtabs;
input trt$ remission y ;
run;

proc print; run;

proc means mean std;
var remission;
run;

proc freq data=liver;
table trt*y;
run;

proc sgplot data=liver;
scatter x=remission y=y /jitter;
run;
```

Example 4.1 SAS

로짓모형 : $\log\left(\frac{p_{\text{trt, remission}}}{1-p_{\text{trt, remission}}}\right) = \alpha + \beta_1 \text{trt} + \beta_2 \text{remission}$

```
proc logistic descending;
   class trt(ref="B");
   model y=trt remission/scale=none aggregate;
   output out=estimated predicted=estprob l=lower95 u=upper95;
run;
```

```
proc logistic plots(only)=(effect oddsratio (type=horizontalstat) roc(id=prob));
   class trt(ref="B");
   model y(event='1')=trt remission/scale=none aggregate lackfit clodds=both  outroc = rocout;
   unit remission=12;
run;
```

Example 4.2

아래 [표 4.8]는 두 종류(T,M)의 종양이 있는 환자들을 대상으로 3가지(A,B,C)의 처리방법으로 그들의 종양이 치료되었는지의 여부를 조사한 자료이다.
설명변수들이 모두 범주형이기 때문에 자료는 분할표식으로 표현된다. 이 때 연구자의 관심은 치료율이 종양의 종류와 처리 방법에 따라 달라지는지 알아보는데 있다.

종류 (type)	처리 (trt)	치료된 환자 수	치료 안된 환자 수
T	A	65	18
M	B	100	13
T	C	56	38
M	A	80	15
T	B	29	9
M	C	78	22

[표 4.8] 종양의 종류와 처리 방법 자료

Example 4.2 SAS

로짓모형 : $\log\left(\frac{p_{\text{type, trt}}}{1-p_{\text{type, trt}}}\right) = \alpha + \beta_1 \text{type} + \beta_2 \text{trt}_1 + \beta_3 \text{trt}_2$

```
data cure;
input type$ trt$ outcome$ count@@;
CARDS;
   T A cured 65  T A uncured 18
   M B cured 100 M B uncured 13
   T C cured 56  T C uncured 38
   M A cured 80  M A uncured 15
   T B cured 29  T B uncured 9
   M C cured 78  M C uncured 22
 ;
run;
```

```
proc logistic plots(only)=(effect oddsratio(type=horizontalstat));
   freq count;
   class type trt;
   model outcome = type trt/scale=none aggregate ;
   output out=cured predicted=pred;
run;
```

다항 반응변수의 경우

- 순서형 반응변수의 경우
  - 비례오즈 (proportional odds) 로짓 모형
  - 이웃범주 (adjacent-categories) 로짓 모형
  - 연속비 (continuation-ratio) 로짓 모형
- 명목형 반응변수의 경우
  - 일반화 (generalized) 로짓 모형

Example 4.3

아래 [표 4.14]는 관절염 통증에 관한 자료이다. 남성과 여성을 2가지(Active, Placebo) 처리방법에 할당하여 통증의 개선도를 '전혀없음(N)', 약간있음(S)', ' 상당히있음(M)', 3가지의 순서형 반응으로 측정하였다. 통증의 개선도가 성별과 처리 방법에 따라 영향을 받는지 알아보고자 한다.

성별	처리	개선도			합
		전혀 없음 (N)	약간 있음 (S)	상당히 있음 (M)	
여	A	6	5	16	27
여	P	19	7	6	32
남	A	7	2	5	14
남	P	10	0	1	11

[표 4.14] 통증 개선도 자료

순서형 반응변수의 경우 : 비례오즈 로짓 모형

- Y : J개의 순서형 범주를 가지고 있는 반응변수
- $(X_1, \ldots, X_k)$: 설명변수 k개
  - $\boldsymbol{x}_i = (x_{i1}, x_{i2}, \ldots, x_{ik})'$: i번째 개체의 설병변수 관측치
- $\pi_{ij} = P(Y = j|\boldsymbol{X} = \boldsymbol{x}_i)$: i번째 개체가 j번째 반응을 나타낼 확률
- i번째 개체가 j번째 반응까지의 누적확률

$$F_{ij} = P(Y \leq j|\boldsymbol{X} = \boldsymbol{x}_i) = \pi_{i1} + \pi_{i2} + \cdots + \pi_{ij}, \ j = 1, \ldots, J$$

순서형 반응변수의 경우 : 비례오즈 로짓 모형

누적로짓 (cummulative logit)

$$
\begin{aligned}
L_j(x_i) = \text{logit}(F_{ij}) &= \log \frac{F_{ij}}{1-F_{ij}},\ j = 1, \ldots, J-1 \\
&= \log \frac{\pi_{i1} + \pi_{i2} + \cdots + \pi_{ij}}{\pi_{ij+1} + \pi_{ij+2} + \cdots + \pi_{iJ}} \\
&= \alpha_j + \beta_1 x_{i1} + beta_2 x_{i2} + \cdots + \beta_k x_{ik} \quad \text{비례오즈모형} \\
&= \alpha_j + \boldsymbol{\beta}' \boldsymbol{x}_i
\end{aligned}
$$

비례가정이 만족되지 않으면 일반화 로짓 모형으로 적합

Example 4.3 SAS

```
DATA improvement;
  INPUT gender $ trt $ improvement $ count @@;
  CARDS;
   f a n 6  f a s 5 f a m 16
   f p n 19 f p s 7 f p m 6
   m a n 7  m a s 2 m a m 5
   m p n 10 m p s 0 m p m 1
    ;
PROC LOGISTIC ORDER=DATA;
  FREQ count;
  CLASS gender trt;
  MODEL improvement=gender trt/SCALE=NONE AGGREGATE;
  OUTPUT OUT=prob pred=p;
RUN;
PROC PRINT data=prob(obs=10); RUN;
```

명목형 반응변수의 경우 : 일반화 로짓 모형

일반화 로짓 (generalized logit)

$$\log \frac{\pi_{ij}}{\pi_{iJ}} = \alpha_j + \beta_{j1}x_{i1} + beta_{j2}x_{i2} + \cdots + \beta_{jk}x_{ik}, \ j = 1, \ldots, J-1$$

$$= \alpha_j + \boldsymbol{\beta}_j'\boldsymbol{x}_i, \quad \boldsymbol{\beta}_j = (\alpha_j, \beta_{j1}, \ldots, \beta_{jk})$$

$\Rightarrow$

$$\pi_{ij} = \frac{\exp(\boldsymbol{\beta}_j'\boldsymbol{x}_i)}{1 + \sum_{k=1}^{J-1}\exp(\boldsymbol{\beta}_k'\boldsymbol{x}_i)}, \ j = 1, \ldots, J-1$$

$$\pi_{iJ} = \frac{1}{1 + \sum_{k=1}^{J-1}\exp(\boldsymbol{\beta}_k'\boldsymbol{x}_i)}$$

Example 4.4

성별과 인종에 따라 어떤 정당을 지지하는가를 조사하여 [표 4.20]과 같은 분할표로 정리하였다. 성별과 인종이 어떤 정당을 지지하는가에 영향을 주는지 알아보고자 한다. 반응변수는 지지하는 정당으로, 민주당(D), 공화당(R), 무소속(I)의 세 항이다. 반응변수의 범주가 어떠한 순서를 가지고 있지 않으므로 일반화된 로짓 모형을 사용하여 분석해 보자.

성별	인종	정당		
		민주당 (D)	공화당 (R)	무소속 (I)
남	백인 (W)	132	176	127
	흑인 (B)	42	6	12
여	백인	172	129	130
	흑인 (B)	56	4	15

[표 4.20] 정당 지지도 자료