~ regression

생명과학자료분석

5장 공분산분석

전북대학교 통계학과

예제 5.1

한 연구자는 저혈당에 걸린 20명의 환자에 대해 혈당을 높이는 서로 다른 5개 치료법의 효능을 비교하고자, 환자 20명을 랜덤하게 5그룹으로 나누어 각각의 치료법을 적용하여 1달 후에 혈당량의 수치를 측정하였다. 그러나 1달 후 혈당량의 수치가 초기 혈당량의 수치에 영향을 받을 것으로 생각하여 초기 혈당량 수치도 함께 측정하였다. 이에 대한 자료는 아래 [표5.3]과 같다.

관측번호	치료법(trt)	x (초기수치)	y (1달 후 수치)
1	1	27.2	32.6
2	1	22.0	36.6
3	1	33.0	37.7
4	1	26.8	31.0
5	2	28.6	33.8
6	2	26.8	31.7
7	2	26.5	30.7
8	2	26.8	30.4
9	3	28.6	35.2
10	3	22.4	29.1
11	3	23.2	28.9
12	3	24.4	30.2
13	4	29.3	35.0
14	4	21.8	27.0
15	4	30.3	36.4
16	4	24.3	30.5
17	5	20.4	24.6
18	5	19.6	23.4

- **분산분석** 처리 간에 반응변수의 모평균의 차이가 있는지 검정
- **공분산 분석**
  - 반응변수의 모평균에 영향을 끼칠 수 있는 처리 외에 또 다른 설명변수가 있다면
  - 처리 간의 차이뿐만 아니라 그 설명변수의 영향도 함께 고려
  - 순수한 처리 간의 차이를 보려면 **설명변수를 보정 (adjust)한 상태**에서
  - **처리 간 반응 변수의 조정된 모평균 (adjusted mean)**의 차이가 있는지 검정

공분산 분석 (ANCOVA)

- 2개 이상의 처리에서 반응변수의 평균을 비교할 때 반응변수에 영향을 주는 연속형 독립변수를 함께 고려하는 경우에 주로 사용
- 연속형 독립변수를 공변량 (covariate)이라고 함
- 공분산 분석= 회귀분석과 분산분석이 결합된 것
  - 각 처리 안에서 공변량을 설명변수로 하는 회귀분석을 시행하고
  - 처리 간 회귀식을 비교
  - 반응변수의 모평균이 처리에 공통적으로 작용하는 공변량에 의해 영향을 받을 때 특히 유용
  - 공변량을 함께 고려하면 이를 고려하지 않은 분산분석보다 추정의 정도 (precision)가 높음

분산분석과의 비교

모형	반응변수	설명변수
분산분석	연속형	범주형
공분산분석	연속형	범주형 + 수치형변수 (공변량)

분산분석과 공분산분석은 회귀분석의 종류로 이해할 수 있음

공분산 분석 (ANCOVA)

- 처리수준이 공변량 값에 영향을 끼쳐서는 안됨

  예) 치료법이 초기혈당에 영향을 끼칠 수 없음

- 공변량과 처리의 교호작용 존재 유무 확인
  - 교호작용이 없다면 반응변수에 대한 공변량의 기울기는 처리수준에 관계없이 일정

    예) 교호작용이 없는 경우 : 치료 1을 받은 환자나 치료 2를 받은 환자나 초기혈당수치가 1달후 혈당량 수치에 미치는 영향이 동일하다고 가정

공분산 분석 (ANCOVA)

- 공변량 효과가 같은 경우
  - 공변량이 하나인 경우 (5.1절)
  - 공변량이 두 개인 경우(5.2절)
- 공변량의 효과가 다른 경우(5.3절)

공변량 효과가 같은 경우

공변량이 하나인 경우의 데이터 형태

처리 1		처리 2		$\cdots$	처리 I	
x_{11}	y_{11}	x_{21}	y_{21}	$\cdots$	x_{I1}	y_{I1}
x_{12}	y_{11}	x_{22}	y_{22}	$\cdots$	x_{I2}	y_{I2}
x_{13}	y_{11}	x_{23}	y_{23}	$\cdots$	x_{I3}	y_{I3}
$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$
x_{1n_1}	y_{1n_11}	x_{2n_2}	y_{2n_2}	$\cdots$	x_{In_I}	y_{In_I}

공분산분석 모형

모형

$$
\begin{aligned}
y_{ij} &= \mu + \alpha_i + \beta(x_{ij} - \overline{X}_{..}) + \epsilon_{ij} \quad (I = 1, \ldots, I,\ j = 1, \ldots, n_i) \\
&= \alpha_i + \beta_0 + \beta x_{ij} + \epsilon_{ij} \\
&= \beta_{0i} + + \beta x_{ij} + \epsilon_{ij}
\end{aligned}
$$

가정

- 오차항 ϵ_{ij}는 동일한 분산을 가지면 정규분포를 따름 (등분산성과 정규성 검정 필요)
- 공변량은 모든 처리에서 같은 효과를 보임 (처리와 공변량의 교호작용 검정 필요)

공분산분석 모형

가설

- $H_{01} : \beta = 0$ (공변량 효과 유무 검정) (귀무가설기각하면 분산분석기법 적용)
- $H_{02} : \alpha 1 = \cdots = \alpha_I$ (처리효과 차이 유무 검정)

참고

- 분산분석 모형 : $y_{ij} = \mu + \alpha_i + \epsilon_{ij}$
- (단순선형) 회귀분석 모형 : $y_{ij} = \beta_0 + \beta x_{ij} + \epsilon_{ij}$

예제 5.1

한 연구자는 저혈당에 걸린 20명의 환자에 대해 혈당을 높이는 서로 다른 5개 치료법의 효능을 비교하고자, 환자 20명을 랜덤하게 5그룹으로 나누어 각각의 치료법을 적용하여 1달 후에 혈당량의 수치를 측정하였다. 그러나 1달 후 혈당량의 수치가 초기 혈당량의 수치에 영향을 받을 것으로 생각하여 초기 혈당량 수치도 함께 측정하였다.

- **반응변수**: 1달 후 혈당량의 수치
- **설명변수**: 치료의 종류(범주형)+초기 혈당수치(양적변수)
- **2가지 연구 문제**
  1) 초기혈당수치를 감안한 상태에서 치료법에 따라 1달 후 혈당 수치에 차이가 있는가?
  2) 치료법의 차이를 감안한 상태에서 초기혈당수치가 1달 후 혈당 수치에 영향을 주는가?

분산분석(ANOVA)+회귀분석 (REGRESSION) $\Rightarrow$ 공분산분석(ANCOVA)

예제 5.1 SAS

〈표 5.5〉 혈당량 자료의 공분산 분석을 위한 SAS 프로그램

```
DATA medicine;
    INPUT trt x y @@ ;
     CARDS;
     1 27.2 32.6 1 22.0 36.6
     1 33.0 37.7 1 26.8 31.0
     2 28.6 33.8 2 26.8 31.7
     2 26.5 30.7 2 26.8 30.4
     3 28.6 35.2 3 22.4 29.1
     3 23.2 28.9 3 24.4 30.2
     4 29.3 35.0 4 21.8 27.0
     4 30.3 36.4 4 24.3 30.5
     5 20.4 24.6 5 19.6 23.4
     5 25.1 30.3 5 18.1 21.8
   ;

PROC GLM;
    CLASS trt;
    MODEL y=trt x  /SOLUTION;
    LSMEANS trt/TDIFF;
RUN;
```

처리 간 회귀계수 β의 동일성 가정 확인 후

MODEL y=trt x 적합

동일성 검정:

MODEL y=trt x trt*x

적합하고 교호작용항 trt*x의 계수가 0인지 검정

SOLUTION 옵션

- 계수 벡터 출력

LSMEANS

- bylevel 옵션 : 처리별 공변량평균 사용하여 보정된 평균
- bylevel 옵션 없으면 처리별 평균대신 공변량 전체평균 사용하여 보정된 평균 (adjusted mean)

다중비교

TDIFF

- 다중비교시 두 처리 간의 차이 유무 검정하고 (모든 가능한 쌍 비교) t값과 p값 출력
- PDIFF=ALL ADJUST=T 과 동일

PDIFF=ALL ADJUST=TUKEY

- Tukey 방법으로 다중비교 (모든 가능한 쌍 비교)

PDIFF=CONTROL("1") ADJUST=DUNNETT

- Dunnet 방법으로 다중비교 (control그룹과 비교)

모형 제곱합 (예제 5.1 SAS)

전체 제곱합 (Total SS: SST) = 모형 제곱합 (Model SS)+오차 제곱합 (Error SS)

모형 제곱합 (Model SS)

- 제 1종 제곱합 (Type I SS) : SS(trt) + SS(x—trt)
  - 두 요인의 기여분 = 제1요인의 기여분+ 제 1요인의 기여 후 제 2요인이 추가로 기여하는 부분
  - Model문의 요인 순서에 따라 값이 달라짐
- 제 3종 제곱합 (Type III SS) : SS(trt—x)+SS(x—trt)
  - 요인의 최종 고유 기여분
  - Model문의 요인 순서와 무관

공분산분석의 주요관심

- 공변량 효과를 제어했을 때 치료법 (trt)에 따라 혈당량의 보정모평균이 차이가 나는가?

공변량이 두 개인 공분산분석 모형

$$y_{ij} = \beta_0 + \alpha_i + \beta_1 x_{1ij} + \beta_2 x_{2ij} + \epsilon_{ij}$$

$$= \beta_{0i} + \alpha_i + \beta_1 x_{1ij} + \beta_2 x_{2ij} + \epsilon_{ij}, \quad \epsilon_{ij} \overset{독립}{\sim} N(0, \sigma^2)$$

예제 5.2

아래 자료는 어떤 약물에 대한 체내배출 연구에서 얻은 자료이다 연구자는 약의 형태에 따라 체내로부터 배출되는 약물량이 달라지는지를 알고자 한다. 그런데 배출되는 약물량은 약의 형태뿐만 아니라 약물의 배출 소요시간과 각 개체의 항신진대사 점수에도 영향을 받을 것으로 생각한다.

관측번호	약의 형태 (type)	항신진대사 점수 (x_1)	측정 시간 (x_2)	약물량 (y)
1	1	37	61	11.3208
2	1	37	37	12.9151
3	1	45	53	18.8947
4	1	41	41	14.6739
5	1	57	41	8.6493
6	1	49	33	9.5238
7	2	49	49	7.6923
8	2	53	53	0.0017
9	2	53	45	8.0477

예제 5.2 SAS

<표 5.12> 약물 배출량 자료의 공분산 분석 SAS 출력 결과

```
data elimination;
  do type=1 to 6;
    input x1 x2 y@@;
    output;
  end;
  cards;
37 61 11.3208 37 37 12.9151 45 53 18.8947
41 41 14.6739 57 41 8.6493 49 33 9.5238
49 49 7.6923 53 53 0.0017 53 45 8.0477
61 37 6.1441 49 65 21.7939 53 53 6.7358
53 45 4.2553 57 57 0.0017 49 49 11.0196
53 53 6.2762 53 45 13.2316 53 53 5.0676
57 57 5.6235 49 49 14.9893 53 53 13.7233
53 45 6.0669 53 53 8.1602 61 37 1.5523
45 45 6.9971 53 45 5.2308 57 57 8.256
49 49 14.5 53 53 20.7627 53 45 3.6115
53 53 11.3475 53 45 9.465 53 53 22.6103
61 37 0.002 49 65 20.5997 37 37 28.1828
;
PROC GLM;
    CLASS type;
    MODEL y=type x1 x2 /solution;
    LSMEANS type/stderr;
RUN;
```

처리식

$\hat{y_{ij}}$ = interc + X_1계수 + X(공변량)

$\hat{y_{ij}}$ = interc + X_2계수 + X(공변량)

$\hat{y_{ij}}$ = interc + X_3계수 + X(공변량)

⋮

$\hat{y_{ij}}$ = interc + X_5계수 + X(공변량)

공변량의 효과가 다른 경우

공변량의 효과가 다른 경우

모형

$$y_{ij} = \beta_0 + \alpha_i + \beta_i x_{ij} + \epsilon_{ij}$$

$$= \beta_{0i} + \alpha_i + \beta_1 x_{ij} + \delta_i x_{ij} + \epsilon_{ij}, \quad \epsilon_{ij} \overset{\text{독립}}{\sim} N(0, \sigma^2)$$

공변량 효과의 동등성 검정

$$H_0 : \delta_i = 0, \ i = 1, \ldots, I$$

예제 5.3

아래 자료는 흡연자를 대상으로 산소운반능력을 개선하는 3개의 서로 다른 치료법을 적용하여 산소운반능력을 조사한 것이다. 연구자의 관심은 각 치료법에 따라 산소운반 능력이 다른가를 보는 것이다. 그런데 산소운반 능력에 영향을 끼치는 중요한 변수로 1인당 담배소비량이 고려되어 이를 공변량으로 하는 공분산 분석을 하려고 한다.

관측번호	치료법(trt)	1인당 담배 소비량(x)	산소운반 능력(y)
1	1	40	165
2	1	54	85
3	1	85	9
4	1	95	43
5	1	81	94
6	1	26	226
7	1	90	7
8	1	95	9
9	1	83	12
10	1	83	145
11	2	85	11
12	2	83	6
13	2	65	51
14	2	98	18
15	2	47	189
16	2	74	90
17	2	75	10

예제 5.3 SAS

<표 5.19> 산소운반 능력 자료의 처리 간 공변량 효과의 동등성 검정결과

```
data oxygen;
input trt x y @@;
cards;
1 40 165 1 54 85 1 85 9 1 95 43 1 81 94
1 26 226 1 90 7 1 95 9 1 83 12 1 83 145
2 85 11 2 83 6 2 65 51 2 98 18 2 47 189
2 74 90 2 75 10 2 97 12 2 79 35 2 91 27
3 65 89 3 25 64 3 34 87 3 20 45 3 30 56
3 29 87 3 100 59 3 85 39 3 24 87 3 26 67
;

proc glm;
  class trt;
  model y=trt x trt*x/solution;
  estimate 'x:trt 1' x 1 x*trt 1 0 0 ;
  estimate 'x:trt 2' x 1 x*trt 0 1 0 ;
  estimate 'x:trt 3' x 1 x*trt 0 0 1 ;
run;
```