생명과학자료분석

7장 생존분석

전북대학교 통계학과

3개의 군으로 쪼개고 생존확률 비교 분석

비호지킨림프종에서 골수흡인 검사 결과에 따른 전체 생존율의 분석

최정윤[1], 강가원[1], 이병현[1], 유은상[1], 김대식[1], 이세련[1], 성화정[1], 김석진[2], 최철원[1], 김병수[1], 박용[1]

목적

비호지킨림프종 환자를 위한 병기 설정 검사는 골수흡인 검사와 골수 조직 검사의 방법으로 시행하게 된다. 두 가지 검사 결과가 일치하면 골수 침범 여부가 명백하나 골수흡인 검사에서만 양성이 나온 경우는 가이드라인이 없으며 임상적으로 논란의 여지가 있다. 따라서 본 연구에서는 이러한 환자군에 대하여 임상적용에 필요한 생존율을 형태학적인 방법으로 비교 분석함으로써 임상적으로 고려해야 할 사안을 검토하는 것으로 하였다.

방법

본 연구는 고려대학교의료원의 림프종 레지스트리에 1991년부터 2016년까지 등록된 환자를 대상으로 하여 대상군은 골수비침습군(BMA-/BMBx-), 흡인 검사에서만 양성이고 조직 검사에서는 음성이 나온 군(BMA+/BMBx-), 조직 검사에서 골수 침범이 확인된 군(BMBx+)으로 구분하였으며 카플란-마이어 생존분석과 다변량 분석을 사용하였다.

결과

환자군은 총 1,735명 중에서 불충분한 결과를 가진 409명을 제외하고 1,326명을 대상으로 하였다. 카플란-마이어 생존분석에서 BMBx+군은 BMA-/BMBx-군과 비교하여 유의하게 좋지 않은 생존율을 보였으나(p < 0.001) BMA+/BMBx와 다른 군 간의 전체 생존율에 대한 유의한 차이는 없었다 (vs. BMA-/BMBx-, p = 0.163; BMBx-, p = 0.292). 그러나 다른 생존율과 관련된 인자들을 보정한 다변량 분석에서 BMA+/BMBx-는 BMA-/BMBx-에 비하여 경계선 상의 유의성을 보여주었으며(p = 0.081) 이는 특히 지연성 비호지킨림프종 환자의 서브그룹 분석에서는 유의한 차이를 나타냈다 (p = 0.003).

결론

비호지킨림프종 환자에서 골수흡인 검사에서만 양성이 나오더라도 불량한 예후를 시사하고 있음을 인지하고 주의를 기울이는 것이 중요하다 하겠다

통계 분석

전체 생존율은 카플란-마이어 방법(Kaplan-Meier method)을 이용하여 평가하였고 그룹 간 비교는 log-rank test를 사용하여 검정하였다. 결과에 대한 예후 변수의 독립적인 효과를 평가하기 위하여 Cox proportional hazards 모델을 사용하여 단변량 및 다변량 분석을 수행하였으며 관련 요인은 backward selection 모델의 사용을 통하여 동시에 고려하였다. 또한 데이터 분석은 SPSS ver. 20.0 (for Windows; SPSS Inc, Chicago, IL, USA)을 사용하였다.

골수군 간 생존율 분석

전체 비호지킨림프종 환자를 대상으로 카플란-마이어 생존 분석에서 전체 생존율은 BMA-/BMBx-에 비하여 BMBx+가 유의하게 낮았다(평균 생존율, 157.1 ± 4.8 vs. 92.7 ± 7.7 months, p< 0.001). 그러나 BMA+/BMBx-와 BMA-/BMBx- 간의 전체 생존율(110.2 ± 14.0 vs. 157.1 ± 4.8 months, p= 0.163; Renyi type test), 그리고 BMA+/BMBx-와 BMBx+ 간의 전체 생존율에 있어서 유의한 차이는 없었다(p= 0.292; Fig. 2).

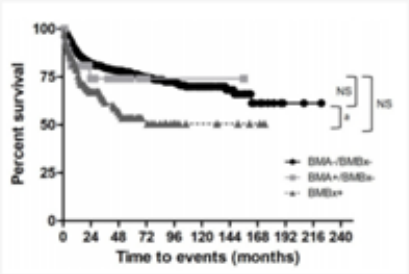


Figure 2

생존시간 (survival time)

생존시간 생존시간 : 관심있는 사건이 일어날 때까지 기다리는 시간

어떤 정의된 시점부터 특정한 사건(event)이 관측될 때까지의 시간

사건의 예) 사망, 처리에 대한 반응, 질병의 재발

생존 분석의 **관심**

Example

- 1년 생존율, 3년 생존율, 환자의 절반이 생존하는 시간
- 두 처리군의 생존분포 비교
- 생존에 영향을 미치는 인자 파악

⇒ **생존시간의 분포**

모집단은 생존시간
모집단의 분포를 알고 싶어한다 일반적으로
그러나 생존분석에서는(사실 일반적인 생명과학에서는)
생존시간의 분포를 가정하지 않음(비모수)
뒤에 준모수도 나옴(분포형태 가정은 안하는데 영향을 주는 요인은 가정)

생존분석의 기초개념

평균보다는
1년 생존율, 3년 생존율
중위수(환자의 절반이 생존하는 시간)
이런 거에 관심 있음

중도절단자료 (censored data)

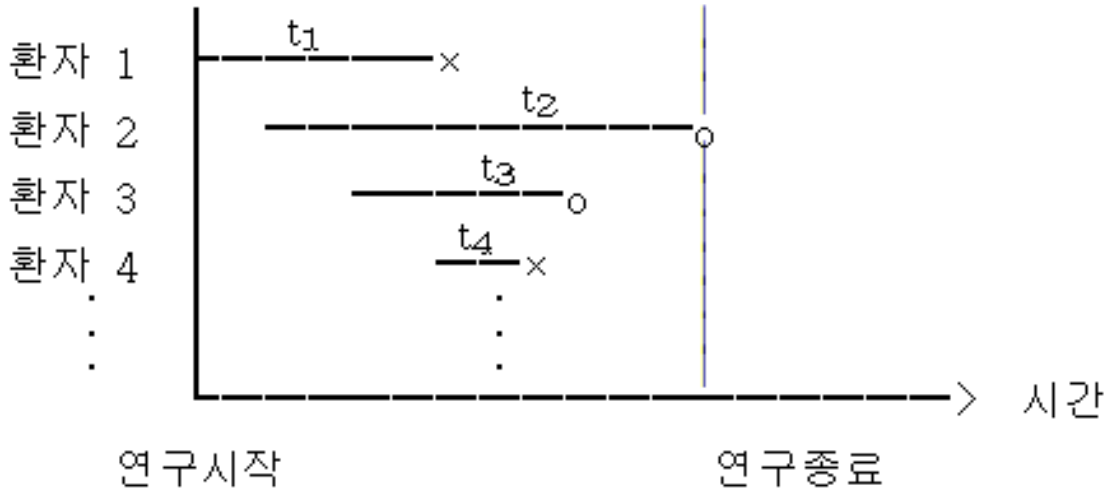
암 실험 결과중에 교통사고로 사망하면 이거는 실험 중 사망한 게 아님
<- 이런 case

연락두절, 질병 아닌 다른 이유로 사망 ← 최소한 마지막 진료시간까지는 생존

중도 절단의 형태

- 제1형태 - 연구자에 의해 중도절단시간 고정 (연구종료시점 정해 놓음)
- 제2형태 - 사전에 관측할 사망자수 정해 놓은 경우
- 제3형태 (임의 중도절단)- 연구자가 제어 못함

<그림 7.1> 임의중도절단 (random censoring) 자료의 예 (×는 사망, 0는 중도절단)



목표는 생존시간의 분포
1 - P(X) = P(X > x)

- 생존시간: $T_1, T_2, \ldots, T_n \overset{iid}{\sim} F$
- 중도절단시간:$C_1, C_2 \ldots, C_n \overset{iid}{\sim} G$
- 관측되는 확률변수 : $(X_1, \delta_1), (X_2, \delta_2), \ldots, (X_n, \delta_n)$

$$X_i = \min(T_i, C_i), \ \delta_i = I(T_i < C_i), \text{즉, 중도절단인 경우 0, 아닌 경우 1}$$

생존분석에 필요한 함수들

- T의 **생존함수 (survival function):** $S(t)$ t시간 이상 생존할 확률
- T의 **위험함수(hazard function):** $h(t)$ t시점까지는 생존했다가 t시점 바로 직후 사망하게 되는 순간 위험률

h있어야함 자료오타

$$S(t) = P(T > t) = 1 - F(t)$$

$$h(t) = \lim_{h \to 0} \frac{P(t < T \leq t + h | T \geq t)}{h} = \frac{f(t)}{S(t)}$$

t시점까지는 살아 있었기에, t <= T

생존함수의 추정: 비모수적, 모수적, 준모수적 방법

비모수로 많이 추정 준모수로 많이 추정

비모수적 방법을 이용한 생존함수의 추정

비모수적 방법

중도절단이 없다면 관측해서 얻은 자료는 t_1, ⋯t_n들

중도절단이 없는 경우

- 생존시간 $x_1, x_2, \ldots, x_n$을 순서대로 배열하여 $t_1 < t_2 < \cdots < t_n$
- 경험적 [redacted]함수

생존

$$\widehat{S}(t_i) = P(\widehat{T > t_i}) = 1 - \frac{i}{n}$$

경험적 분포함수를 중도절단 있는 경우로 확장

$$= \quad \hat{S}(t_i) = \frac{\#(T>t_i)}{n} = \frac{n-i}{n} = 1 - \frac{i}{n}$$

- **생명표(life table)방법** -(환자 수가 상당히 많을 때) 관측 자료를 시간의 단위로 묶어 추정
- **누적한계추정법(product-limit method)** - 환자 개개인의 관측 자료의 시점에서 추정

생명표방법

- 생존시간을 k개의 구간으로 나눔

$$(t_{i-1}, t_i], \ i = 1, \ldots, k+1, t_0 = 0, \ t_{k+1} = \infty$$

- n_i: i번째 구간 시작 시점에서 생존자 수
- d_i: i번째 구간에서 사망자 수
- c_i: i번째 구간에서 중도절단 인원수
- p_i: i번째 구간 내에서의 생존률

더 큰 범위(전체나)에서 나머지 사망자들 빼면 구할 수 있음(해당구간)

$$p_i = P(i\text{번째 구간에서 내내 생존}|i\text{번째 구간의 시작점에서 생존})$$

$$= P(T > t_i | T > t_{i-1})$$

- $q_i = 1 - p_i$
- $n_i = n_{i-1} - d_{i-1} - c_{i-1}$
- n_i' : 유효인원수 (effective sample size) $= n_i - \frac{c_i}{2}$

생명표방법

Note that

$$S(t_i) = P(T > t_i)$$

$$= P(T > t_1)P(T > t_2 | T > t_1) \cdots P(T > t_i | T > t_{i-1})$$

$$= p_1 p_2 \cdots p_i$$

$$\frac{P(T>t_i) \cap P(T>t)}{P(T>t_{i-1})} = \frac{P(T>t_i)}{P(T>t_{i-1})}$$

생명표방법 생존함수 추정치

$$\widehat{S}(t_i) = \prod_{j=1}^{i} \widehat{p}_j$$

t_i 시간 이상 생존할 확률은 예를들어 첫 번째 1년 내의 생존율, 두번째 1년 내 생존율, 9년내 1년내 생존율 즉, 각 구간의 생존율을 구해서 곱하면 됨

여기에서 $\widehat{p}_j$ 는 j번째 구간에서의 생존율 추정치

$$\widehat{q}_j = \frac{d_j}{n'_j}, \ \widehat{p}_j = 1 - \widehat{q}_j$$

각 구간별 생존율은 각 구간별 사망율을 구해도 구할 수 있음, 이 때 중도 절단도 계산

추정된 생존함수의 분산

$$\widehat{Var}(\widehat{S}(t_i)) = \widehat{S}^2(t_i) \sum_{j=1}^{i} \frac{d_j}{n'_j(n'_j - d_j)}$$

$$\frac{d}{n - \frac{c}{2}}$$

표본 비율에서 나온 것이기 때문에 추정된 생존함수의 분포의 경우 표준 정규분포 따름

생명표방법

〈표 7.1〉 생명표의 형태

구간	사망자수	중도절단수	위험그룹 인원수	유효인원수	사망율	생존율	생존함수
$(t_0, t_1]$	d_1	c_1	n_1	n_1'	$\hat{q}_1$	$\hat{p}_1$	$\hat{S}(t_1)$
$(t_1, t_2]$	d_2	c_2	n_2	n_2'	$\hat{q}_2$	$\hat{p}_2$	$\hat{S}(t_2)$
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
$(t_{i-1}, t_i]$	d_i	c_i	n_i	n_i'	$\hat{q}_i$	$\hat{p}_i$	$\hat{S}(t_i)$
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

예제 7.1

다음의 [표 7.2] 는 협심증(angina pectoris)이 있는 2418명의 남성들에 대한 생존자료이다. 진단시점부터 사망할 때까지의 시간이 생존시간으로 계산되었으며, 1년 간격으로 표가 작성되었다. 이 생명표에서 경과기간에 따른 생존확률을 구해보자.

$S(t_2) = p_1 \cdots p_2$

$S(t_7) = p_1 \cdots p_7$

$\hat{p}_k = 1 - \hat{q}_k$

$\hat{q}_k = \frac{d_k}{n_k}$

〈표 7.2〉 협심증 환자의 생존자료

진단 후 경과기간 (단위:년)	사망자수	중도절단수
(0 - 1]	456	0
(1 - 2]	226	39
(2 - 3]	152	22
(3 - 4]	171	23
(4 - 5]	135	24
(5 - 6]	125	107
(6 - 7]	83	133
(7 - 8]	74	102
(8 - 9]	51	68
(9 - 10]	42	64
(10 - 11]	43	45
(11 - 12]	34	53
(12 - 13]	18	33
(13 - 14]	9	27
(14 - 15]	6	23
(15 -	0	30

예제 7.1 SAS

〈표 7.3〉 협심증자료의 생명표를 위한 SAS program

```
data angina;
 do time= 0.5 to 15.5;
 do censor=1, 0;
 input freq@@;
 output;
 end;
 end;
 cards;
 456 0  226 39 152 22 171 23 135 24 125 107 83 133 74
 102 51 68 42 64 43 45 34 53 18 33 9 27 6 23 0 30
;

proc lifetest method=life
     intervals= 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15
     plots=(s,h) graphics;
  time time*censor(0);
  freq freq;
run;
```

$X_i = \min(T_i, C_i)$

→ 생존시간이 짧으면 생존시간 관측값 중도절단 〃 중도절단 〃

누적한계추정법-Kaplan-Meier 추정법

- n_i:시점 t_i에서 위험에 노출된 인원수 t_i시점에 관측하고 있던 수

  즉, 바로 t_i직전까지 중도절단되지 않고 생존해 있던 인원수

- d_i : t_i전까지 사망한 수 t_i에 사망한 수(수정본에 그렇게 적힘)

누적한계추정치

$$\widehat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right)^{\delta_i}$$

추정된 생존함수의 분산

$$\widehat{Var}(\widehat{S}(t)) = \widehat{S}^2(t) \sum_{i:t_i \leq t} \frac{d_i}{n_i(n_i - d_i)}$$

누적한계추정법-Kaplan-Meier 추정법

Remarks

- 일치성, 근사적 정규성 만족. 표본 클때 통계적 성질 우수.
- 중도절단시간에는 변하지 않고 사망이 관측된 시점에서 $(n_i - d_i)/n_i$ 곱해준만큼 감소.
- 사망과 중도절단이 동시에 발생한 경우 사망이 중도절단보다 먼저 관측된 것으로 봄.
- 마지막 생존시간 t_n이 중도절단된 경우 t_n이후 시간에 대한 추정치 정의 안함.

예제 7.2

여기 기말문제 낸다고 함

다음의 [표 7.5]는 신장이식수술을 받은 15명 환자들의 호전기간 (remission duration)이다. 여기서 +로 표시된 것은 중도절단된 자료를 가리킨다.

〈표 7.5〉 신장이식환자들의 호전기간 (단위: 일)

3.0	4.0+	4.5	4.5	5.5	6.0	6.4	6.5	7.0	7.5
8.4+	10.0	10.0+	12.0	15.0					

〈표 7.6〉 신장이식환자자료의 누적한계추정법을 위한 SAS 프로그램

```
data rem;
input time censor @@;
cards;
3.0 1 4.0 0 4.5 1 4.5 1 5.5 1 6.0 1 6.4 1 6.5 1 7.0 1
7.5 1 8.4 0 10.0 1 10.0 0 12.0 1 15.0 1
;
```

Km = 케플란 마이어, s = survival

```
proc lifetest method=km plots=(s) graphics;
time time*censor(0);
run;
```