Introduction to SAS

SAS (Statistical Analysis System)

- 1966년도에 미국 노스캐롤라이나 대학교에서 농업 연구 과제로부터 시작
- 1976년도에 SAS Institute Inc. 설립
- 1997년부터 매년 가장 일하기 좋은 기업으로 선정 (Fortune지)
- 147개국 75000곳에서 이용



Why SAS?

- 긴 역사, 매우 다양한 프로시져
- 취업시 유용
- 신뢰성, 안정성
- 빅데이터
- 문서작업
- 도움말

SAS 국제 공인 자격증

- SAS Base, SAS Advanced Programmer 등 4종
- 한국어로 응시 가능
- https://www.sas.com/ko_kr/training/home/int-certificate/tab_02.html

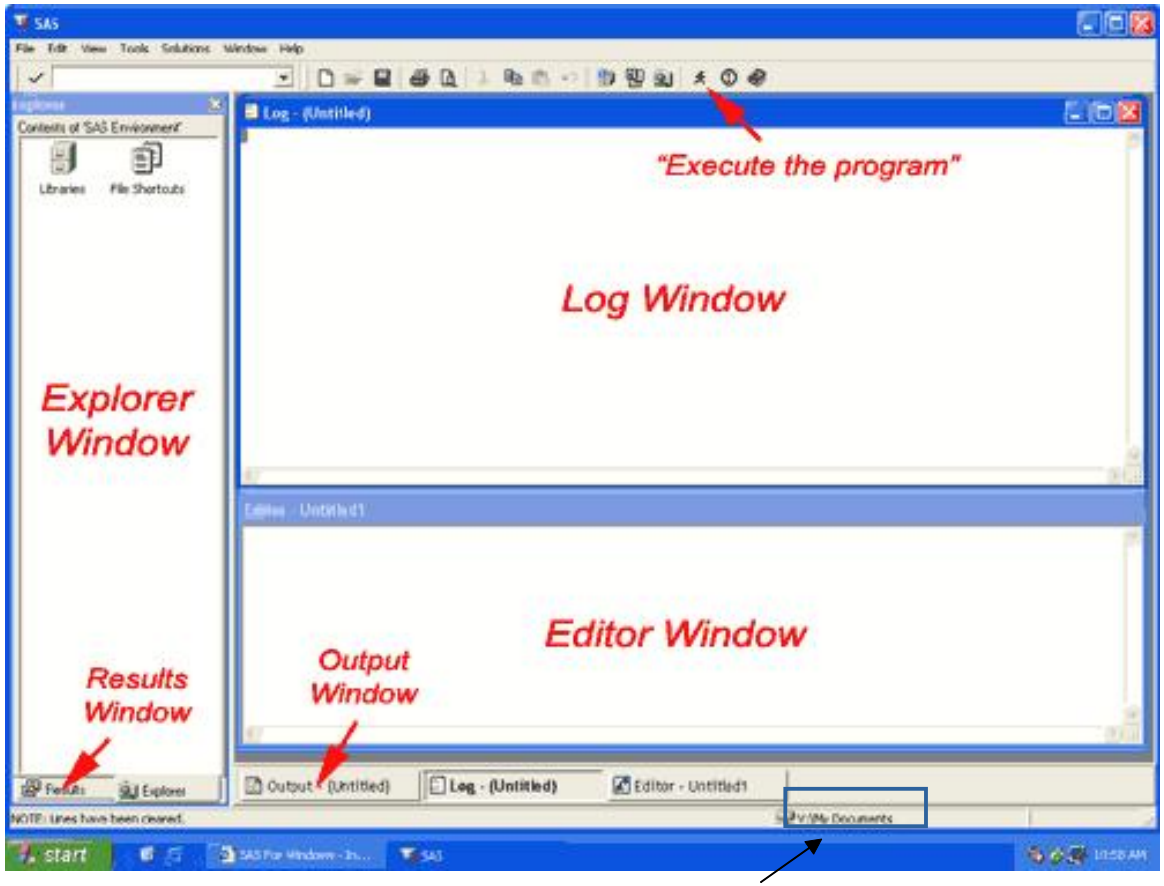
1. SAS 윈도우의 구성

① 확장편집기 윈도우: SAS 프로그램 작성

② 출력 윈도우: 결과출력

③ 로그 윈도우:수행과정 및 ERROR 출력

④ 기타 (그래프 등의 출력결과, 탐색기)



* working directory로 먼저 변경하고 시작

2. SAS 프로그램의 기본구조

DATA step - dataset 생성 및 수정

PROC step - dataset을 가지고 특정 작업 수행

```
/* 기본적인 프로그램의 구조 */
DATA data_name;
   INPUT  variable1 variable2 $ @@;
   CARDS;
    data1 data2 data3 data4 data5 data6
    data7 data8 data9 data10 data11 data12
    ;
RUN;

PROC procedure_name OPTION;
   VAR  variable1;
   BY variable2;                          /*BY는 proc sort로 정렬한 변수만 사용*/
   OUTPUT OUT=data_name_1 keywords;    /*저장장소*/
RUN;
```

- 모든 명령문은 세미콜론(;)으로 끝냄
- 대소문자구별 없음
- 설명문 /*....*/ 또는 *.....;
- 한줄에 여러 문장 가능

예) **proc print** data=grade;

```
      var subject gender;
   run;
```

다음과 동일

```
proc print data=grade; var subject gender;  run;
```

3. 예제 프로그램

```
/******* example1.sas ***********************/
title "Example: getting started with SAS";

data grade;
       input subject gender$ exam1 exam2 hwgrade$;
       datalines;    /* cards;*/
       10 M 80 84 A
       7 . 85 89 A
       4 F 90 . B
       20 M 82 85 B
       25 F 94 94 A
       14 F 88 84 C
       ;
run;

proc print data=grade;
       var subject gender;
run;
```

- 실행 – 마우스로 실행시키고자하는 부분을 블록으로 선택한 후
  마우스 우클릭하고 *선택실행*을 클릭 또는 F3 클릭

4. Data step

dataset 생성

- SAS editor 에서 **직접 입력** 하거나
- 데이터 파일 (txt, csv, xlsx, sas7bdat 등) 을 읽어서 (**import**) 생성
- 확장자 '.sas7bdat' 로 생성됨

1) 직접 입력

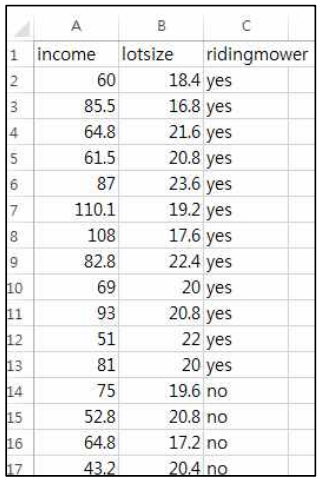
- DATA : 데이터셋 이름 입력
- INPUT : 변수명 입력
- DATALINES or CARDS : 자료 입력 시작
- ; : 자료 끝
- **RUN** : 자료 입력 수행

```
DATA  grade;
   INPUT  subject gender$ exam1 exam2 hwgrade$;    /* gender 와 hwgrade은 문자변수*/
   DATALINES;  /* CARDS;로 대체 가능*/
   .......
   ;
RUN;
```

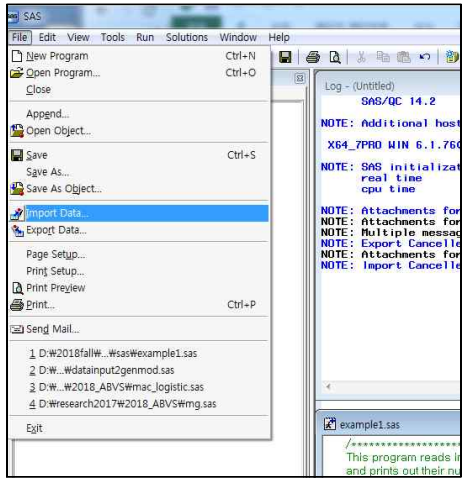
2) 데이터 파일을 읽어서 생성 (import)

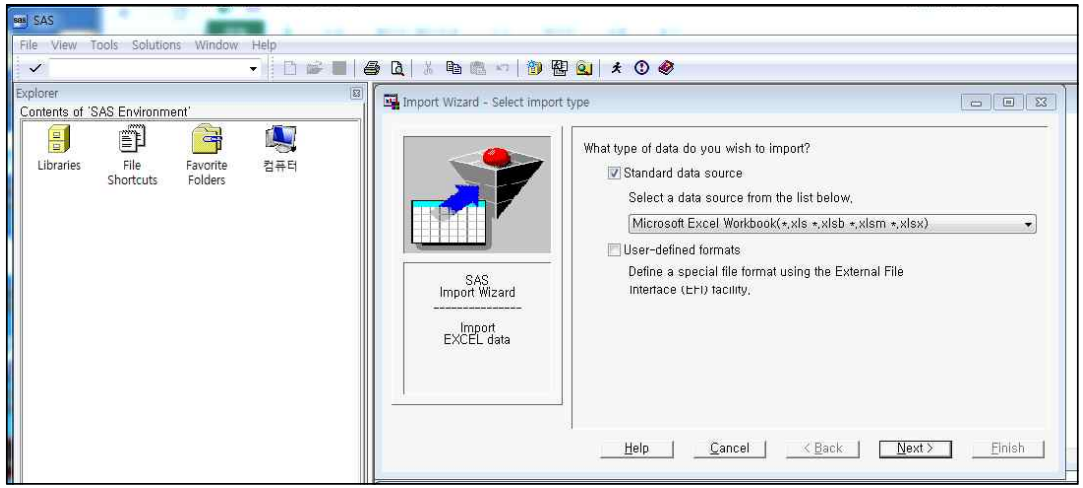
- File 메뉴 아래의 *데이터 가져오기*(import data) 선택하여 파일 (xls, xlsx, csv, txt 등) 읽기

예) mower.xlsx 자료를 sas로 불러들여 mower 라는 dataset 만들기



	A	B	C
1	income	lotsize	ridingmower
2	60	18.4	yes
3	85.5	16.8	yes
4	64.8	21.6	yes
5	61.5	20.8	yes
6	87	23.6	yes
7	110.1	19.2	yes
8	108	17.6	yes
9	82.8	22.4	yes
10	69	20	yes
11	93	20.8	yes
12	51	22	yes
13	81	20	yes
14	75	19.6	no
15	52.8	20.8	no
16	64.8	17.2	no
17	43.2	20.4	no





3) 영구적인 DATA 생성 (**라이브러리**)

- SAS Library : SAS dataset 이 저장 되는 위치, 컴퓨터 내의 폴더
- Default : Work library (임시 라이브러리) - SAS 를 나가면 사라지는 임시 자료
- 라이브러리 지정 (LIBNAME)

예) `LIBNAME sclass 'C:\Users\USER\Desktop\SAS_class\data';`

- 위에서 DATA 문으로 생성된 자료는 SAS를 끝내면 사라지는 임시 data set, 즉 work 라이브러리에 저장되어 있음

- SAS를 끝내도 계속 남아 있는 data set 생성을 위해 library를 만들어 저장.

```
LIBNAME sclass 'C:\Users\USER\Desktop\SAS_class\data';
DATA sclass.x;
   INPUT x1-x3; /*변수이름 x1 x2 x3 */
   DATALINES;
        1  1  12.4
        1  2  11.3
        1  3   1.4
        2  1   2.1
        2  2  19.4
        2  3  10.0
        ;
RUN;
proc print data=sclass.x; run;
```

■ dataset 다루기 : merge, set, if, label...

① set : 포함된 변수들이 동일한 여러 데이터셋의 결합

② merge

- 한 개 이상의 동일 변수를 포함하고 있는 여러 데이터셋을 하나의 동일 변수를 기준으로 결합
- 각 데이터셋은 결합변수를 기준으로 정렬되어 있어야 함

③ 한 데이터셋을 여러 데이터셋으로 나누기

```
data mow_y;
  set mower;
  if ridingmower="yes";  *or where ridingmower="yes";
run;

data mow_n;
  set mower;
  if ridingmower ne "yes";
run;

/* 참고
data mow_y1 mow_n1;
  set mower;
  if  ridingmower="yes" then output mow_y1;
  else output mow_n1;
run;
*/

data mow_yn;
  set mow_y mow_n;
  label ridingmower="Do they have a riding mower?";
run;

/* 참고
proc append base=mow_y data=mow_n;       run;*/
```

```
data mow_inc;
  set mower (keep=income ridingmower);
  id=_n_;
run;

/* 참고
proc sort data=mow_inc; by id;   run; */


data mow_lot;
  set mower (keep=lotsize ridingmower);
  id=_n_;
run;

data mow_inclot;
  merge mow_inc mow_lot;
  by id;
run;
```

5. PROC step

```
proc contents data=mower; run; /*mower data의 구조와 변수 형식 파악*/
proc print data=mower (obs=10); /*처음 10개의 observation만 출력*/
run;
```

```
proc format;
  value incgrp low-40="Low"
               40<-80="Middle"
               80<-high="High";
  value  $yngrp "yes"="Y"
                "no"="N";
run;

proc print data=mower;
  format income incgrp. ridingmower $yngrp.;
run;

data mower_f;
  set mower;
  format income incgrp. ridingmower $yngrp.;
run;
```

```
proc means data=mower_f;
  var income;
run;

proc freq data=mower_f;
  table income ridingmower income*ridingmower;
run;
```

```
proc sort data=mower out=mower_s; /* mower data를 income 기준으로 정렬해서 mower_s로 저장*/
       by  income;
run;
```

6. 결과 저장

- ods html (pdf, rtf); ... ods html (pdf, rtf) close;
  - html, xls, pdf, word로 저장
  - html은 default

```
ods pdf file='mower_mean.pdf';
proc means data=mow;
   var income lotsize;
run;
ods pdf close;
```

- proc 실행하면 기본적으로 많은 표들이 출력되는데, 이들 중 특정 표만 출력하고 싶다면

  ods output <output table 이름>;

(각 표의 이름은 "sas proc 프로시저 이름 ods table names"로 구글링)

- 여기에 그 table을 dataset으로 저장하고 싶다면

  ods output <output table 이름=데이터셋 이름 지정> ;

- proc report를 이용하여 customized table 출력

```
proc univariate data=mow;
   var income lotsize;
   ods output BasicMeasures=dmeas;
run;
proc contents data=dmeas; run;


PROC REPORT data= dmeas NOWINDOWS HEADLINE;
     title '기초 통계량';
     column VarName LocMeasure LocValue;
     define VarName /width=6 "변수/이름" center;
     define LocMeasure/width=6 center;
     define LocValue/ FORMAT = comma5.2 right;
RUN;
```

예제 SASHELP안에 내장된 자료 class의 summary

- 범주형 변수: proc freq
- 수치형 변수: proc means, proc univariate

```
proc contents data=sashelp.class position; run;
```

```
title 'Frequency count of sex';

proc freq data=sashelp.class;
       tables sex;
run;

proc freq data=sashelp.class;
       tables sex/nocum;
run;
```

결측치가 있는 경우: 이를 반영하려면 missing, missprint 옵션 사용

```
proc means data=sashelp.class;run;

proc means data=sashelp.class; var  age height; un;

proc means data=sashelp.class maxdec=2 fw=10;
       var  age height;
run;

proc means data=sashelp.class maxdec=2 fw=10 sum range median;
       var  age height;
run;
```

```
/* Grouping */
proc means data=sashelp.class maxdec=2 fw=10;
       var  age height;
       class sex;
run;

/*Summary Table*/

PROC SORT data =sashelp.class out = class2;
  by sex;
RUN;

PROC MEANS data=class2 NOPRINT;
  var age height;
       by sex;
  output out = clsummary
            mean = MeanAge MeanHeight
            median = MedianAge MedianHeight;
RUN;

PROC PRINT;
 title 'Class Statistics';
RUN;

/* univariate procedure*/
proc univariate data=sashelp.class normal plot;
       var height;
run;
```

예제 SASHELP안에 내장된 자료 cars

```
proc contents data=sashelp.cars;run;
```

상자그림

```
proc sgplot data=sashelp.cars;
title "Box Plot: Category = Origin";
vbox Horsepower / category=Origin;
run;

proc sgplot data=sashelp.cars ;
title "Box Plot: Group = Origin";
vbox Horsepower / group=Origin;
run;

proc sgplot data=sashelp.cars;
title "Box Plot: Category = Cylinders, Linear Scale";
vbox horsepower / category=cylinders; /* cylinders: numeric */
xaxis type=linear;
run;

proc sgplot data=sashelp.cars;
where Type in ('SUV' 'Truck' 'Sedan');
title "Box Plot: Category = Origin, Group = Type";
vbox horsepower / category=Origin Group=Type;
run;
```

산점도

```
proc sgplot data=sashelp.cars;
  title"Vehicles: All Origins";
  scatter x=wheelbase y=weight / markerattrs=(symbol=CircleFilled);
run;

proc sgplot data=sashelp.cars;
  title"Vehicles: All Origins";
  scatter x=wheelbase y=weight / markerattrs=(symbol=CircleFilled) group=origin;
run;

proc sgplot data=sashelp.cars;
 title"Vehicles: Origin=USA only";
 where origin="USA";
scatter x=wheelbase y=weight / markerattrs=(symbol=CircleFilled);
run;
```

과제

bweight.csv 파일을 읽어 dataset을 만들고 2개의 수치형 변수와 2개의 범주형변수를 선택하여 요약 정리해보기. (표와 그래프)

bweight 자료 설명

National Center for Health Statistics (Koenker and Hallock 2001; Abreveya 2001)에서 제공한 1997년 출생 체중 데이터

흑인 또는 백인으로 분류된 18세에서 45세 사이의 어머니의 신생아 체중 기록

1	Weight	신생아 체중
2	Black	흑인 어머니 여부
3	Married	기혼 어머니 여부
4	Boy	남자 아이 여부
5	MomAge	어머니 나이
6	MomSmoke	흡연 어머니 여부
7	CigsPerDay	하루 흡연량
8	MomWtGain	어머니의 임신기간 체중 증가량
9	Visit	산전 병원 방문 여부
10	MomEdLevel	어머니의 교육수준